

Problemformulering

Formålet med dette projekt var at forudsige, om en person tjener mere end 50.000 USD om året baseret på census-data fra Adult Income datasættet.

Projektet er et supervised machine learning klassifikationsproblem, hvor target-variablen består af to klasser:

- $\leq 50K$
- $> 50K$

Projektet inkluderer:

- data preprocessing
- modeltræning
- hyperparameter tuning
- evaluering af modeller
- sammenligning af modelarkitekturer

Datasæt

Projektet benytter Adult Income datasættet fra UCI Machine Learning Repository.

[Adult Dataset \(UCI\)](#)

Datasættet indeholder cirka 48.000 rækker og 14 features.

Eksempler på features:

- alder
- uddannelse
- occupation
- marital-status
- arbejdstimer pr. uge

Datasættet indeholder både numeriske og kategoriske features.

Data preprocessing omfattede:

- håndtering af manglende værdier
- one-hot encoding af kategoriske features
- train/test split

Adult		
Donated on 4/30/1996		
Predict whether annual income of an individual exceeds \$50K/yr based on census data. Also known as "Census Income" dataset.		
Dataset Characteristics	Subject Area	Associated Tasks
Multivariate	Social Science	Classification
Feature Type	# Instances	# Features
Categorical, Integer	48842	14

Modelarkitekturer

Random Forest

Random Forest er en ensemble learning metode, der kombinerer flere decision trees for at forbedre accuracy og reducere overfitting.

Der blev udført hyperparameter tuning med GridSearchCV ved hjælp af parametre som:

- `n_estimators`
- `max_depth`
- `min_samples_split`

Den tunede Random Forest model opnåede en accuracy på cirka 86%.

Gradient Boosted Trees

Projektet undersøgte også Histogram-Based Gradient Boosting.

Gradient Boosting træner decision trees sekventielt, hvor hvert træ forsøger at rette fejl fra tidligere træer.

Der blev udført hyperparameter tuning med GridSearchCV ved hjælp af parametre som:

- `learning_rate`
- `max_iter`
- `max_depth`

Gradient Boosting modellen opnåede den højeste accuracy på cirka 87%.

Repository

Github repository med Jupyter Notebook:

<https://github.com/najamoe/MLEexam.git>

Konklusion

Projektet demonstrerede en komplet machine learning workflow med data preprocessing, ensemble learning, hyperparameter tuning og evaluering af klassifikationsmodeller.